

Tarea 1: MongoDB

Profesor: José Luis Martí Lara
Ayudante: Eduardo Rodríguez Prado

1. Introducción

Las bases de datos documentales corresponden a un tipo de base de datos NoSQL que gestionan los datos mediante documentos, comúnmente representados utilizando formatos como JSON o BSON. Una de sus principales características es la flexibilidad de esquema, permitiendo que los documentos de una misma colección puedan contener estructuras diferentes.

Para esta tarea se utilizará MongoDB como sistema gestor de base de datos documental. El objetivo será poner en práctica operaciones de consulta, búsqueda sobre arreglos y documentos embebidos, pipelines de agregación, actualización de documentos y análisis del procesamiento de consultas mediante índices y “explain()”.

2. Contexto del caso

Una empresa ficticia llamada “Voice Managers” dedicada a mantener información sobre actores y actrices de voz desea migrar su catálogo hacia una base de datos documental. Actualmente necesita almacenar información personal básica de cada actor o actriz, junto con datos relacionados con los personajes que ha interpretado, las producciones en las cuales ha participado y otros antecedentes relevantes.

Debido a que un actor o actriz puede interpretar múltiples personajes y cada personaje puede estar relacionado con diferentes características de una producción, se ha decidido utilizar MongoDB para representar esta información mediante documentos, arreglos y documentos embebidos, como saben que usted domina completamente MongoDB, le han pedido su ayuda.

A lo largo de la tarea se deberá construir esta base de datos, realizar diferentes tipos de consultas y posteriormente analizar cómo cambia su ejecución al incorporar índices.

3. Set Up

Para empezar a realizar lo que se solicitará a continuación es necesario instalar [MongoDB Community Server](#) y [MongoDB Compass](#). Durante la instalación del primero debe seleccionar la instalación completa y colocar siguiente hasta el final, es normal que el proceso tarde algunos minutos. Para mayor detalle en la instalación consultar este video.

Luego deberá instalar [Docker](#) (A elección de ustedes si prefieren por consola o la aplicación, *los archivos que se facilitaran están probados solo con Docker Desktop*), en Aula se encontrara el archivo “docker-compose.yml” (pueden crear uno ustedes, pero debe tener por lo menos 3 nodos) con el cual levantarán los contenedores con MongoDB, y para la conexión con compass utilizar el siguiente string:

```
mongodb://localhost:30001,localhost:30002,localhost:30003/?replicaSet=my-replica-set
```

Una vez instalado todo, se debe crear una base de datos llamada “Actors” y una colección llamada “Voice-actors” en donde debe insertar los datos del JSON que creara usted.

4. Desarrollo

Para esta tarea deberá elaborar un informe en formato PDF que contenga los resultados obtenidos en cada una de las siguientes partes. Se deberán incluir las consultas utilizadas, capturas de sus resultados y una breve explicación de lo realizado.

Preparación de los datos — 10 puntos

Cree datos ficticios e ingréselos a MongoDB. Puede utilizar inteligencia artificial o desarrollar un script para facilitar su generación. La colección deberá contener **al menos 20 actores o actrices de voz**. Los datos generados deben ser suficientemente variados para permitir realizar correctamente todas las consultas solicitadas posteriormente.

Cada documento deberá contener, como mínimo, los siguientes atributos:

- **Nombre:** nombre completo de la persona.
- **Nacionalidad:** país donde nació.
- **Fecha de nacimiento.**
- **Edad:** última edad registrada.
- **Patrimonio:** patrimonio estimado de la persona.
- **Idiomas:** arreglo simple que indique uno o más idiomas en los que la persona ha realizado trabajos de doblaje (puede ponerlo sin caracteres especiales como tildes o ñ). Por ejemplo:

[‘Español’, ‘Inglés’]

- **Personajes:** arreglo compuesto por documentos embebidos. Cada personaje deberá contener, al menos:
 - Nombre del personaje.
 - Serie, película, anime o videojuego al que pertenece.
 - Tipo de producción: profesional o independiente.
 - Rol: principal, secundario o extra.
 - Cantidad de apariciones.
 - Géneros de la producción, almacenados como un arreglo simple.

Estos son los atributos mínimos requeridos. Puede incorporar atributos adicionales si lo considera necesario.

Parte 1: Consultas — 10 puntos

Realice las siguientes consultas utilizando MongoDB Query Language (MQL).

Salvo que se indique lo contrario, las consultas deberán cumplir con las siguientes condiciones:

- Mostrar como máximo 10 documentos.
- Presentar los resultados utilizando algún orden ascendente o descendente.
- Mostrar como máximo cuatro campos mediante una proyección.
- Incluir el campo “Nombre” dentro de los datos mostrados.

1. Proyección, filtrado y ordenamiento sobre campos simples.

Realice una consulta que muestre únicamente actores o actrices de voz **mayores de 50 años**.

2. Búsqueda dentro de un arreglo simple.

Seleccione una nacionalidad y un idioma existentes dentro de sus datos y realice una consulta que muestre actores o actrices de dicha nacionalidad que contengan ese idioma dentro del arreglo “Idiomas”.

3. Búsqueda sobre arreglos de documentos embebidos.

Realice una consulta que muestre actores o actrices de voz **menores de 30 años** que posean, al menos, un personaje cuyo rol sea “Principal”.

Además, la consulta deberá considerar un valor contenido dentro del arreglo **géneros** del mismo personaje.

Por lo tanto, la búsqueda deberá trabajar con:

- Un arreglo de documentos embebidos.

- Campos pertenecientes a dichos documentos.
- Un arreglo contenido dentro de un documento embebido.

Se recomienda investigar el operador “\$elemMatch” para asegurar que las condiciones correspondan al mismo elemento del arreglo.

4. Pipeline de agregación.

Utilizando “\$aggregate()”, muestre actores o actrices ordenados de acuerdo con su patrimonio. Deberá obtener **10 registros comenzando desde la quinta posición** del resultado ordenado.

Parte 2: Procesamiento de consultas — 40 puntos

En esta sección deberá analizar cómo MongoDB ejecuta las consultas anteriores y observar el efecto producido por la creación de índices.

1. Ejecución sin índices — 2 puntos

Ejecute las consultas realizadas en la Parte 1 utilizando:

```
.explain("executionStats")
```

Para las consultas realizadas mediante `find()` utilice la sintaxis correspondiente de `explain()`, mientras que para el pipeline de agregación deberá utilizar la forma apropiada para analizar un `aggregate()`. Guarde los resultados obtenidos antes de crear los índices.

2. Índice sobre Nacionalidad — 4 puntos

Cree un índice para realizar búsquedas sobre el campo:

“Nacionalidad”

Luego vuelva a ejecutar con *.explain("executionStats")* la consulta de la Parte 1 que utiliza dicho campo. Compare el nuevo plan de ejecución con el obtenido antes de crear el índice.

3. Índice sobre Edad — 4 puntos

Cree un índice para realizar búsquedas sobre el campo:

“Edad”

Vuelva a ejecutar con *.explain("executionStats")* las consultas de la Parte 1 que utilizan la edad como condición de búsqueda. Compare los resultados con los obtenidos antes de crear el índice.

4. Comparación de planes de ejecución — 15 puntos

Analice los resultados obtenidos antes y después de crear los índices. Responda si existieron cambios en la forma en que MongoDB procesó las consultas y explique dichos cambios.

Como mínimo, deberá revisar y explicar cuando corresponda:

- COLLSCAN.
- IXSCAN.
- Cantidad de documentos examinados.
- Cantidad de claves examinadas.
- Cantidad de documentos retornados.
- Tiempo de ejecución reportado.
- Plan seleccionado por MongoDB.

No basta con indicar que una consulta fue “más rápida”; deberá relacionar su explicación con la información entregada por `.explain("executionStats")`.

5. Escalabilidad — 15 puntos

Suponga ahora que la colección deja de contener aproximadamente 20 documentos y pasa a contener **10 mil millones de documentos**.

Explique qué podría ocurrir con:

- Las consultas ejecutadas sin índices.
- Las consultas que pueden utilizar los índices creados.
- La cantidad de documentos que MongoDB tendría que examinar.
- El tiempo y recursos necesarios para procesar las consultas.
- El almacenamiento adicional requerido por los índices.

A partir de lo observado con “`explain()`”, explique por qué el diseño de índices se vuelve relevante al trabajar con grandes volúmenes de datos.

Parte 3: Flexibilidad de esquema, resiliencia y actualización — 39 puntos

1. Flexibilidad de esquema — 10 puntos

Suponga que se inserta un nuevo actor o actriz de voz, pero el documento no contiene el atributo “Fecha de nacimiento”.

Responda:

- ¿MongoDB permitiría insertar el documento?
- ¿Qué consecuencias podría tener posteriormente?
- ¿Considera conveniente permitir documentos con atributos faltantes en este caso?

- ¿Existe alguna forma de controlar o validar la estructura de los documentos en MongoDB?

2. Resiliencia de la base de datos — 5 puntos

En Docker detenga el nodo primario de MongoDB y luego ejecute cualquier consulta. Pasos en windows, para saber cual es el nodo principal (en Linux quizás sea similar):

- a) Ejecutar en powershell “docker exec -ti mongo1 bash”
- b) Después en la nueva terminal ejecutar “mongosh –port 30001”
- c) Si dice primario botar ese, sino, ejecutar los comandos anteriores cambiando a mongo2 y el puerto a 30002 o mongo3 con el puerto 30003 (*los puertos y nombres de mongo son los del docker-compose de Aula, si usted uso otro debe poner sus variables*)

Responda, ¿Funciono la consulta?¿Por qué?

3. Actualización masiva de documentos — 24 puntos

Debido a un golpe de suerte, todos los actores y actrices de la colección participaron realizando doblaje para la nueva serie animada:

“Sansa Ball Race”

Lo que incremento su popularidad, por lo tanto, usted deberá actualizar todos los documentos de la colección.

Para simplificar el problema, puede asignar el mismo nombre de personaje a todos los actores y actrices. La actualización deberá cumplir las siguientes condiciones:

- Agregar el nuevo personaje al arreglo “Personajes” de todos los documentos.
- Para actores o actrices **menores de 40 años**, el personaje tendrá:
 - Rol: “principal”.
 - Cantidad de apariciones: 3.
- Para actores o actrices de **40 años o más**, el personaje tendrá:
 - Rol: “secundario”.
 - Cantidad de apariciones: 1.
- El patrimonio de **todos** los actores y actrices deberá incrementarse en un **32 %**.

Realice esta modificación utilizando operaciones de actualización de MongoDB. La solución debe ser eficiente, es decir, cambios manuales o documento a documento se consideraran como respuestas erróneas.

Incluya evidencia de los documentos antes y después de realizar la actualización.

Parte 4: Cierre — 1 punto

Una vez finalizada la tarea y obtenidas todas las evidencias necesarias, elimine la base de datos creada. *Todo lo que empieza debe terminar.*

Importante: En caso de necesitarlo, puede utilizar un repositorio de GitHub para adjuntar las imágenes de sus consultas y el archivo JSON con los datos creados.

En caso de utilizar GitHub, el repositorio deberá ser **público**.

5. Sobre la entrega

1. La tarea es individual.
2. Es necesario entregar un informe en formato PDF que contenga las respuestas a cada sección, las consultas realizadas, sus respectivos resultados y capturas que evidencien el proceso. Se recomienda utilizar GitHub u otro método para almacenar las imágenes cuando esto permita mantener el informe ordenado. El informe deberá contener nombre y rol del estudiante. Puede ser realizado utilizando Word, L^AT_EX u otra herramienta, siempre que la entrega final corresponda a un archivo PDF.
3. La fecha de entrega es hasta las 23:59 del Viernes 11 de septiembre de 2026.

Las consultas relacionadas con la tarea pueden ser realizadas mediante Discord o al correo:

eduardo.rodriquezp@usm.cl

No se responderán consultas realizadas durante las 24 horas previas a la fecha límite de entrega.

6. Entregable, descuentos y cálculo de nota

La tarea constará de dos partes a evaluar: el entregable disponible en Aula y una defensa realizada mediante [Discord](#).

1. El entregable deberá contener como mínimo:
 - JSON con los datos generados, en caso de que este no sea entregado mediante un repositorio GitHub.
 - Informe en formato PDF con los resultados obtenidos.
 - En caso de utilizar un repositorio GitHub, deberá incluirse su enlace dentro del informe.
2. La defensa consistirá en responder una serie de preguntas relacionadas directamente con los contenidos utilizados durante el desarrollo de la tarea.

Se realizarán aproximadamente entre 5 y 10 preguntas cortas.

Dependiendo de la respuesta, se asignará:

- 0 puntos: respuesta errónea o no responde.
- 0.5 puntos: respuesta parcialmente correcta.
- 1 punto: respuesta correcta.

Las preguntas de la defensa podrán abordar, entre otros temas:

- Consultas y operadores utilizados.
- Proyecciones y ordenamientos.
- Arreglos simples.
- Documentos embebidos y arreglos anidados.
- Pipelines de agregación.
- Planes de ejecución.
- Uso y funcionamiento de índices.
- Escalabilidad.
- Actualizaciones de documentos.
- Flexibilidad de esquema de MongoDB.
- Resistencia ante caídas de Docker.

La nota se calculará de la siguiente manera:

$$NF = I \cdot N_D$$

donde I corresponde a la nota obtenida a partir del puntaje del informe y N_D se calculará de la siguiente forma:

$$N_D = \frac{C_r}{C_t}$$

donde C_r corresponde a la cantidad de puntos obtenidos durante la defensa y C_t corresponde a la cantidad total de preguntas realizadas.

Notar que N_D puede ser 0.

A continuación se detallan los posibles descuentos:

- Si no se respeta la entrega en formato PDF, se realizará un descuento de **15 puntos**.

- Si el archivo no contiene nombre y rol, se realizara un descuento de **30 puntos**.
- Se descontarán **10 puntos** por cada hora de atraso o fracción, aproximada hacia arriba, en la entrega del informe en Aula.
- No entregar el JSON con los datos generados tendrá un descuento de **50 puntos**.
- En caso de utilizar GitHub para almacenar imágenes o el archivo JSON y el repositorio no sea público, se aplicará la sanción correspondiente si no es posible acceder al material requerido. Si las imágenes necesarias para evaluar una sección no son accesibles, dicha sección podrá no ser evaluada.
- Llegar tarde a la defensa tendrá un descuento de **5 puntos**. Además, el estudiante contará con menos tiempo disponible para responder.

Por ejemplo, si por falta de tiempo solo se responden 5 de 8 preguntas, las tres preguntas restantes se considerarán con puntaje 0. **No se otorgará tiempo adicional.**

- **No agendar un horario de defensa implica nota 0 inmediata.**
- **No asistir a la defensa implica nota 0 inmediata.**